LAPORAN PRAKTIKUM MACHINE LEARNING
LINEAR REGRESSION

Oleh:

Nama : Dyelvio Wijaya

NIM : 211344012

Tanggal Praktikum : 24 Oktober 2023

Tanggal Pengumpulan Laporan : 27 Oktober 2023

PRODI D4 TEKNIK TELEKOMUNIKASI - TEKNIK ELEKTRO
POLITEKNIK NEGERI BANDUNG

OKTOBER 2023

A. Program Linear Regression

Import Library

```
[40] import matplotlib.pyplot as plt #"mengimport library matplotlib.pylot lalu akan dipanggil dalam program dengan plt"
     import pandas as pd #"mengimport library pandas lalu akan dipanggil dalam program dengan pd"
     import pylab as pl #"mengimport library pylab lalu akan dipanggil dalam program dengan pl"
     import numpy as np #"mengimport library numpy lalu akan dipanggil dalam program dengan np"
     #"untuk menampilkan plot secara langsung di dalam notebook"
     %matplotlib inline
```

Dowload Data

```
[5] !wget "https://cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud/IBMDeveloperSkillsNetwork-ML0101EN-SkillsNetwork/labs/Module%202/data/FuelConsumptionCo2.csv" #dowload file yang ada di dalam link

--2023-10-24 13:26:34--  https://cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud/IBMDeveloperSkillsNetwork-ML0101EN-SkillsNetwork/labs/Module%202/data/FuelConsumptionCo2.csv
Resolving cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud (cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud)... 169.45.118.108
Connecting to cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud (cf-courses-data.s3.us.cloud-object-storage.appdomain.cloud)|169.45.118.108|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 72629 (71K) [text/csv]
Saving to: 'FuelConsumptionCo2.csv'

FuelConsumptionCo2. 100%[===================>]  70.93K  --.-KB/s    in 0.06s

2023-10-24 13:26:34 (1.13 MB/s) - 'FuelConsumptionCo2.csv' saved [72629/72629]
```

Reading The Data

```
[9] df = pd.read_csv("FuelConsumptionCo2.csv") #"memuat sebuah file FuelConsumptionCo2.csv ke dalam sebuah dataframe yang akan disimpan ke variabel df"

    # take a look at the dataset
    df.head() # "melihat beberapa baris pertama dari data yang berada pada variabel df"
```

Output Program:

	MODELYEAR	MAKE	MODEL	VEHICLECLASS	ENGINESIZE	CYLINDERS	TRANSMISSION	FUELTYPE	FUELCONSUMPTION_CITY	FUELCONSUMPTION_HWY	FUELCONSUMPTION_COMB	FUELCONSUMPTION_COMB_MPG	CO2EMISSIONS
0	2014	ACURA	ILX	COMPACT	2.0	4	AS5	Z	9.9	6.7	8.5	33	196
1	2014	ACURA	ILX	COMPACT	2.4	4	M6	Z	11.2	7.7	9.6	29	221
2	2014	ACURA	ILX HYBRID	COMPACT	1.5	4	AV7	Z	6.0	5.8	5.9	48	136
3	2014	ACURA	MDX 4WD	SUV - SMALL	3.5	6	AS6	Z	12.7	9.1	11.1	25	255
4	2014	ACURA	RDX AWD	SUV - SMALL	3.5	6	AS6	Z	12.1	8.7	10.6	27	244

Data Exploration

```
[12] # summarize the data
     df.describe() #merangkum data yang ada dalam df
```

Output Program:

	MODELYEAR	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_CITY	FUELCONSUMPTION_HWY	FUELCONSUMPTION_COMB	FUELCONSUMPTION_COMB_MPG	CO2EMISSIONS
count	1067.0	1067.000000	1067.000000	1067.000000	1067.000000	1067.000000	1067.000000	1067.000000
mean	2014.0	3.346298	5.794752	13.296532	9.474602	11.580881	26.441425	256.228679
std	0.0	1.415895	1.797447	4.101253	2.794510	3.485595	7.468702	63.372304
min	2014.0	1.000000	3.000000	4.600000	4.900000	4.700000	11.000000	108.000000
25%	2014.0	2.000000	4.000000	10.250000	7.500000	9.000000	21.000000	207.000000
50%	2014.0	3.400000	6.000000	12.600000	8.800000	10.900000	26.000000	251.000000
75%	2014.0	4.300000	8.000000	15.550000	10.850000	13.350000	31.000000	294.000000
max	2014.0	8.400000	12.000000	30.200000	20.500000	25.800000	60.000000	488.000000

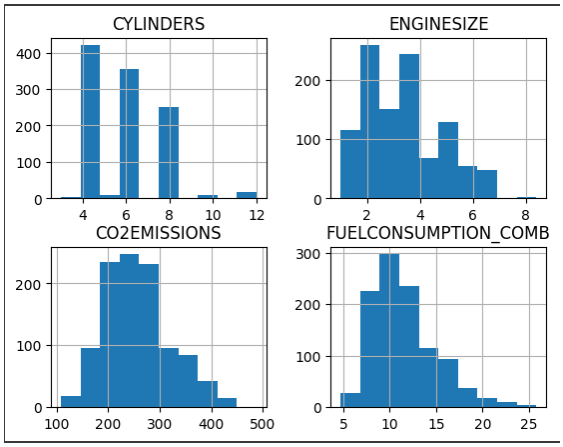
```
cdf = df[['ENGINESIZE','CYLINDERS','FUELCONSUMPTION_COMB','CO2EMISSIONS']] #mengambil data tertentu dan dimasukkan ke dalam cdf
cdf.head(9) #menampilkan 9 baris dari data yang ada dalam cdf
```

Output Program:

	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_COMB	CO2EMISSIONS
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267

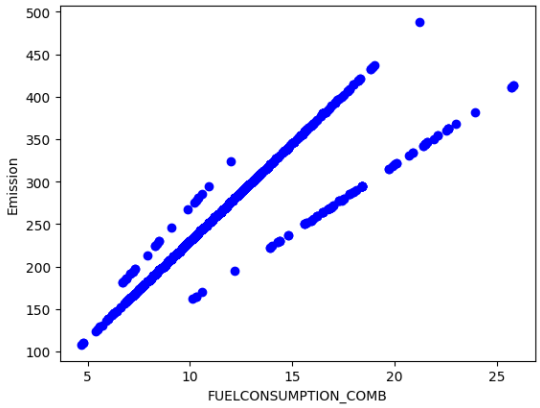
```
viz = cdf[['CYLINDERS','ENGINESIZE','CO2EMISSIONS','FUELCONSUMPTION_COMB']] #mengambil data tertentu dan dimasukkan ke dalam viz
viz.hist() # untuk membuat histogram dari data yang ada dalam viz
plt.show() # untuk menampilkan histogram
```

Output Program:



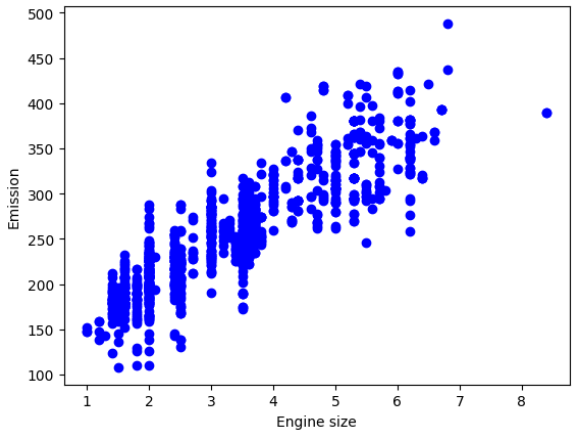

```
plt.scatter(cdf.FUELCONSUMPTION_COMB, cdf.CO2EMISSIONS,  color='blue') # perintah untuk membuat scatter plot dengan sb x adalah FUELCONSUMPTION_COMB dan sb y CO2EMISSIONS dengan warna biru
plt.xlabel("FUELCONSUMPTION_COMB") # perintah memberi label pada plot sb x dengan keterangan FUELCONSUMPTION_COMB
plt.ylabel("Emission") # perintah memberi label pada plot sb y dengan keterangan Emission
plt.show() # menampilkan plotting
```

Output Program:



```
plt.scatter(cdf.ENGINESIZE, cdf.CO2EMISSIONS,  color='blue')
plt.xlabel("Engine size")
plt.ylabel("Emission")
plt.show()
```

Output Program:

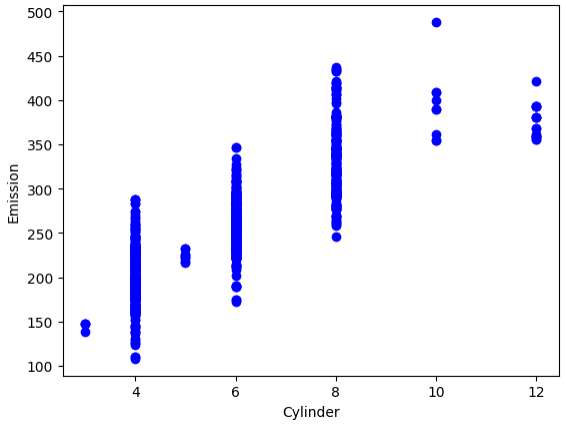


B. Practice

Plot **CYLINDER** vs the Emission, to see how linear is their relationship is:

```
# write your code here
plt.scatter(cdf.CYLINDERS, cdf.CO2EMISSIONS,  color='blue')
plt.xlabel("Cylinder")
plt.ylabel("Emission")
plt.show()
```

Output Program:



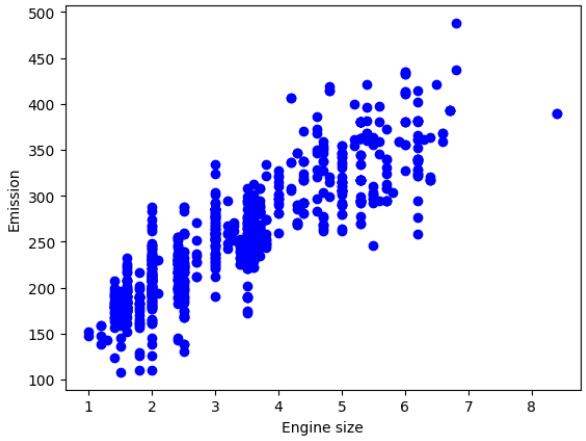
Creating train and dataset

```
[19] msk = np.random.rand(len(df)) < 0.8 #untuk memilih sekitar 80% dari data secara acak untuk data pelatihan
     train = cdf[msk] #memasukan data 80% ke dalam train
     test = cdf[~msk] #memasukan data 20% ke dalam train (~ = negasi)
```

Train Data Distribution

```
plt.scatter(train.ENGINESIZE, train.CO2EMISSIONS,  color='blue') #plotting scatter untuk data train saja yaitu untuk ENGINESIZE dan CO2EMISSIONS
plt.xlabel("Engine size")
plt.ylabel("Emission")
plt.show()
```

Output Program:



Modeling

```
from sklearn import linear_model #mengambil library dari sklearn untuk lib linear_model
regr = linear_model.LinearRegression() #objek regr digunakan untuk melatih model regresi linear
train_x = np.asanyarray(train[['ENGINESIZE']]) #proses konversi dari data asli ENGINESIZE menjadi array
train_y = np.asanyarray(train[['CO2EMISSIONS']]) #proses konversi dari data asli CO2EMISSIONS menjadi array
regr.fit(train_x, train_y) #melakukan pelatihan model regresi linear dengan menggunakan data train
# The coefficients
print ('Coefficients: ', regr.coef_)# mencetak nilai tingkat kemiringan
print ('Intercept: ',regr.intercept_)# mencetak nilai ketinggian awal
```

Output Program:

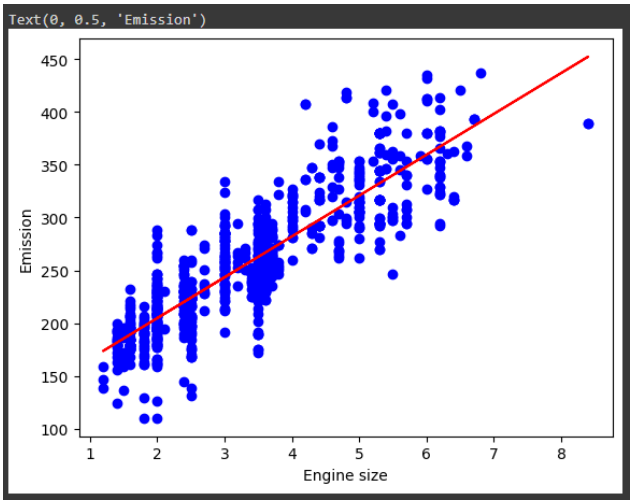
```
Coefficients:  [[38.71086399]]
Intercept:  [127.25363626]
```

Plot Outputs

```
plt.scatter(train.ENGINESIZE, train.CO2EMISSIONS,  color='blue')
plt.plot(train_x, regr.coef_[0][0]*train_x + regr.intercept_[0], '-r') #perintah untuk membuat plot garis regresi
#train_x = variabel independen yang digunakan sebagai sumbu x (horizontal) dalam plot
#regr.coef_[0][0] = Ini adalah koefisien (slope) dari model regresi linear yang telah dilatih
#regr.intercept_[0] = ntercept dari model regresi linear, yaitu nilai konstanta (y-intercept) dalam rumus garis regresi
# -r =  parameter opsional yang menggambarkan garis sebagai garis putus-putus merah
plt.xlabel("Engine size")
plt.ylabel("Emission")
```

Output Program:

```
Text(0, 0.5, 'Emission')
```



Evaluasi

```
from sklearn.metrics import r2_score #mengambil library dari sklearn.metrics untuk lib r2_score

test_x = np.asanyarray(test[['ENGINESIZE']])
test_y = np.asanyarray(test[['CO2EMISSIONS']])
test_y_ = regr.predict(test_x) #perintah untuk melakukan prediksi untuk test_x menggunakan model regresi linear

print("Mean absolute error: %.2f" % np.mean(np.absolute(test_y_ - test_y))) #mencetak MAE dari hasil prediksi (test_y_) dibandingkan dengan nilai sebenarnya (test_y)
print("Residual sum of squares (MSE): %.2f" % np.mean((test_y_ - test_y) ** 2)) #mencetak MSE dari hasil prediksi (test_y_) dibandingkan dengan nilai sebenarnya (test_y)
print("R2-score: %.2f" % r2_score(test_y , test_y_) ) #mencetak R-squared (R^2) score atau coefficient of determination
```

Output Program:

```
Mean absolute error: 24.02
Residual sum of squares (MSE): 1005.73
R2-score: 0.79
```

C. Exercise

Lets see what the evaluation metrics are if we trained a regression model using the `FUELCONSUMPTION_COMB` feature.

Start by selecting `FUELCONSUMPTION_COMB` as the train_x data from the `train` dataframe, then select `FUELCONSUMPTION_COMB` as the test_x data from the `test` dataframe

```
train_x = train[["FUELCONSUMPTION_COMB"]]

test_x = test[["FUELCONSUMPTION_COMB"]]
```

Now train a Linear Regression Model using the `train_x` you created and the `train_y` created previously

```
[44] regr = linear_model.LinearRegression()

     regr.fit(train_x, train_y)
```

```
LinearRegression
LinearRegression()
```

Find the predictions using the model's `predict` function and the `test_x` data

```
[42] predictions = regr.predict(test_x)
```

Finally use the `predictions` and the `test_y` data and find the Mean Absolute Error value using the `np.absolute` and `np.mean` function like done previously

```
[43] #ADD CODE
     print("Mean absolute error: %.2f" % np.mean(np.absolute(predictions - test_y)))
```

```
Mean absolute error: 2.33
```

D. Analisa

Linear Regresi adalah sebuah teknik machine learning yang berbasis supervised. Model regresi linear ini digunakan untuk membuat sebuah prediksi dari nilai nilai variabel yang independen. Sehingga dapat digunakan untuk memprediksi nilai variabel yang bersifat dependen, dengan catatan jika kita memiliki nilai nilai variabel independen yang sesuai. Dalam linear regresi ini kita menggunakan beberapa library yaitu matplotlib.pyplot, pandas, pylab, dan numpy. Kemudian dalam proses impor library terdapat as yang dimana kata setelahnya nanti yang akan digunakan untuk memanggil atau menggunakan library tersebut. Kemudian dalam mengunduh sebuah data dapat menggunakan perintah !wget. Pada sebuah program terdapat salah satu contoh seperti berikut :

pd.read_csv(“Nama File.csv”)

Dalam program diatas dapat diketahui bahwa setelah titik itu adalah sebuah fungsi yang terdapat dalam sebuah library pd(pandas), sehingga dapat dikatakan bahwa program diatas adalah untuk membaca sebuah file csv menggunakan fungsi yang sudah ada pada lib pandas

dengan cara pd.read_csv(). Kemudian dalam fungsi head() adalah berfungsi untuk menunjukkan beberapa baris yang ada dalam variabel. Kemudian untuk fungsi describe() disini digunakan untuk merangkum semua informasi yang ada dalam sebuah data.

Lalu dalam proses untuk penampilan atau pengambilan sebuah kolom kolom tertentu dalam sebuah data, dapat menggunakan sebuah program dengan contoh sebagai berikut:

```
cdf = df[['ENGINESIZE','CYLINDERS','FUELCONSUMPTION_COMB','CO2EMISSIONS']]
```

Dalam program diatas ini dapat terlihat bahwa varibel cdf hanya akan diisi oleh data ENGINESIZE, CYLINDERS, FUELCONSUMPTION_COMB, CO2EMISSIONS. Kemudian untuk menampilkan sebuah histogram dapat menggunakan fungsi namavariabel.hist(), kemudian untuk menampilkan sebuah histogramnya atau plot dapat menggunakan fungsi plt.show().

Dalam library plt(matplotlib.pyplot), terdapat banyak fungsi yang digunakan dalam linear regresi ini yaitu diantaranya scatter() fungsi ini digunakan untuk membuat plot scatter, xlabel() atau ylabel() untuk memberikan nama/keterangan dalam plot, dan show() untuk menampilkan plot.

Dalam sebuah linear regresi dalam sebuah testing apakah model berjalan dengan baik atau tidaknya dapat dilakukan dengan membagi data untuk sebagian menjadi data untuk train, dan data sisanya untuk data test. Seperti layaknya manusia, mesin juga perlu porsi yang lebih besar dalam belajar, sehingga saat testnya nanti dapat berjalan atau menghasilkan output yang sesuai atau bagus. Sehingga dalam praktikkum kali ini digunakan 80% untuk train dan 20% untuk test. Kemudian dalam proses modeling perlu adanya penggunaan library baru yaitu sklearn dan import linear_model. Kemudian nantinya kita pilih modelnya yaitu linear regresi dan masukkan ke dalam sebuah objek. Kemudian untuk data yang akan kita buatkan modelnya perlu dirubah terlebih dahulu ke dalam tipe data array. Kemudian untuk melakukan proses training model linear regresi dapat menggunakan fungsi fit(data_a, data_b). Apabila ingin mengetahui nilai coeficient dapat memanggil atribut coef, dan untuk mengetahui intercept dapat memanggil atribut intercept.

Kemudian dalam proses evaluasi model untuk mengetahui baik atau tidaknya model dapat mencari nilai MAE, MSE, dan juga R-2. Untuk nilai MAE jika semakin rendah maka model yang dibuat semakin baik kinerjanya, dan MSE jika semakin rendah maka model yang dibuat semakin baik kinerjanya, lalu untuk R-2 jika semakin mendekati 1 maka model yang dibuat semakin baik kinerjanya. Dapat dilihat dalam program exercise nilai MAE untuk FUEL CONSUMPTION_COMB didapatkan nilai yang kecil sehingga dapat dikatakan lebih baik daripada training model yang menggunakan ENGINESIZE.